

國立臺南大學資訊工程學系
115 級畢業專題期中進度報告

基於 Social 與 xLSTM
預測交通車流量之研究

A Study on Traffic Flow Prediction Based
on Social Pooling and xLSTM

專案編號：NUTN-CSIE-PRJ-115-006

組員：S11159005 黃毓峰

S11159028 唐翊靜

指導老師：陳宗禧 教授

國立臺南大學資訊工程學系
畢業專題期中進度報告審定書

基於 Social 與 xLSTM
預測交通車流量之研究

A Study on Traffic Flow Prediction Based
on Social Pooling and xLSTM

學生 學號: S11159005 姓名:黃毓峰

學號: S11159028 姓名:唐翊靜

所提之報告內容符合本學系大學部畢業專題實作標準。

指導教授：陳宗禧

系主任：高啟洲

中華民國 114 年 6 月

目錄

第壹章	動機與問題	1
1.1	研究動機	1
1.2	研究問題	1
第貳章	研究方法	2
2.1	基準模型：Long Short-Term Memory, LSTM	2
2.2	Social LSTM（含社交池化）	3
2.3	擴展型 LSTM（xLSTM）	4
2.4	本文提出的 Social-xLstm.....	5
第參章	資料集與前處理	7
3.1	資料集來源.....	7
3.2	資料集蒐集.....	7
3.3	資料前處理.....	7
3.4	選擇交通預測所需監測站	7
第肆章	實驗結果.....	9
4.1	效能評估	9
第伍章	應用設計.....	10
第陸章	預期結果.....	11
6.1	預期結果	11
6.2	目前完成工作	11
6.3	預期完成工作	11
第柒章	期中進度.....	12
7.1	進度甘特圖.....	12
7.2	實驗結果	12
參考文獻	13

圖目錄

圖 1 LSTM unit with gating mechanism	3
圖 2 公路局所提供各監測設備之相對位置.....	8
圖 3 所選擇監測站點分布.....	8
圖 4 進度甘特圖.....	12

表目錄

表 1 長短期記憶網路 (LSTM) 核心元件與功能	3
表 2 Social Pooling 架構優勢	4
表 3 xLSTM 核心元件與功能	5

第壹章 動機與問題

1.1 研究動機

隨著都市化與車輛數量的飆升，台灣主要城市的交通壅塞日益嚴重，促使交通管理單位極需更精準且即時的流量預測，以支援訊號控制、事件應變和長期運輸規劃。近年深度學習模型（如 LSTM [1]、圖卷積網路 [2] 與 Transformer [3]）在複雜時空序列建模上展現優越性能，能顯著降低短期與中期流量預測誤差，已成為智慧交通系統核心技術。

然而，多數時空圖模型預設已知道路拓撲或感測器連接資訊，對於節點佈局缺乏或不完整的新興資料集，建模門檻仍高；即便採用動態或自適應鄰接矩陣，也須額外估算相似度或交通拓撲。這樣的先決條件限制了模型的泛用性與部署彈性。

本研究借鏡 Social LSTM [4] 在行人軌跡預測中透過隱式「社交池化」捕捉鄰近互動的概念，提出將其延伸為固定 x, y 感測器座標的 Social xLSTM 流量預測框架。此架構以上一時刻之流量與相關時段特徵作為輸入，透過內部池化機制自動學習各感測站間的隱含依賴，而不需預先指定節點連線或道路拓撲。

1.2 研究問題

根據現有交通預測模型多半仰賴完整拓撲資訊或預定義鄰接關係，對於資料不完整或節點分布不規則的情境適應性不足的現象，本研究進一步提出以下研究問題：

- a. 在缺乏完整拓撲資訊或明確節點連線設定的交通感測資料下，是否能透過基於座標的社交池化機制，有效學習節點間的空間互動關係？
- b. 本研究提出的 Social xLSTM 模型，是否能在不明確指定鄰接關係的情況下，自動建構節點依賴結構，並應用於交通流量預測？
- c. 相較於傳統依賴靜態圖結構的模型，Social xLSTM 是否能在節點分布不規則或拓撲資料不完整的情境中，保持預測精度與穩定性？
- d. 社交池化（Social Pooling）機制是否能根據座標與時間動態資訊，有效捕捉區域間即時流量互動，進而提升對流量變化（如壅塞、事件）的預測敏感度？
- e. Social xLSTM 是否能在節點關聯未知或模糊時，自動學習相對合理的空間結構，降低人工建模與前處理的負擔？

第貳章 研究方法

都市交通感測器節點的佈局往往不規則，且缺乏完整道路拓樸資料，致使多數依賴靜態圖結構的時空預測模型（如 GCN-LSTM、ASTGNN）在實務部署上受限。為降低對先驗鄰接關係的依賴，本章提出一套由座標驅動、可自動學習節點互動的流量預測框架，並依下列邏輯組織內容：

1. 基準模型：Long Short-Term Memory, LSTM

先回顧 LSTM 如何透過門控與細胞狀態解決長期依賴問題，作為時間序列建模基線。

2. Social LSTM（含社交池化）

介紹 Social Pooling 以周邊座標劃分網格、隱式捕捉鄰近互動的機制，說明其在行人軌跡領域的啟發性。

3. 擴展型 LSTM (xLSTM)

說明 xLSTM 透過可重寫、高容量記憶（sLSTM/mLSTM）克服標準 LSTM 儲存侷限，為後續模型提供更大的鍵值存取能力。

4. 本文提出的 Social-xLstm

將 Social Pooling 與 xLSTM [5] 記憶結構整合，建立一個無需先驗拓樸、僅依賴固定座標即可自動學習節點依賴的交通流量預測模型。模型以前一時刻流量與時段特徵為輸入，透過內部池化適應節點分布不規則或拓樸資料不完整的場景。

2.1 基準模型：Long Short-Term Memory, LSTM

2.1.1 動機與角色

LSTM 由 Hochreiter 與 Schmidhuber (1997) 提出，藉由「細胞狀態」與「門控機制」形成常數誤差迴圈 (CEC)，有效抑制 RNN 在長序列反向傳播時的梯度消失問題。對交通流量預測而言，尖峰壅塞與離峰通行之間往往跨越數百個時間步（數十分鐘至數小時），LSTM 可在不依賴外部拓樸的情況下捕捉長期趨勢，因而被本研究選為時間序列建模的基準模型 (baseline)。

2.1.2 單元結構

LSTM 單元由三個閘門與 x_t 個細胞狀態組成如圖 1 以及表 1 所示。

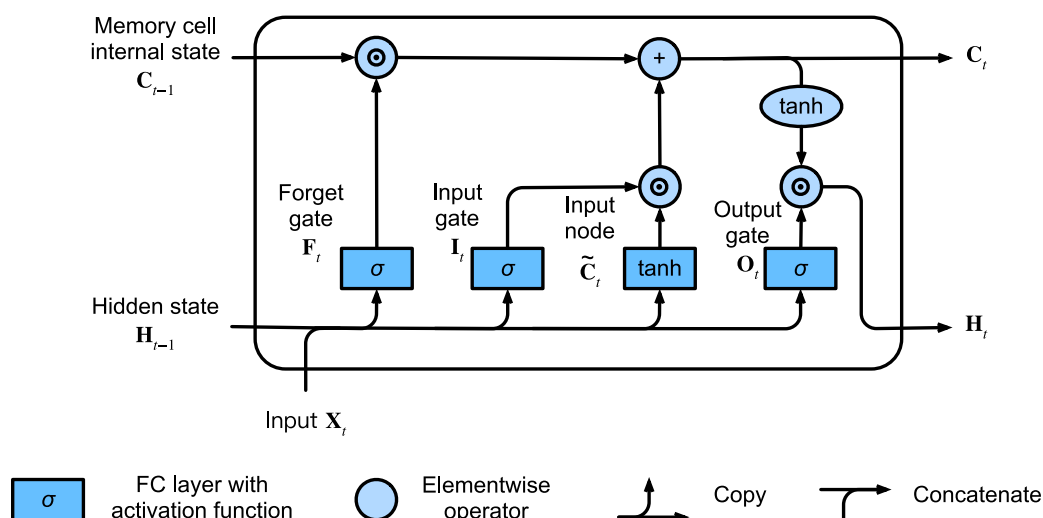


圖 1 LSTM unit with gating mechanism

表 1 長短期記憶網路 (LSTM) 核心元件與功能

元件	符號	功能概述
Input Gate	I_t	決定哪些新的資訊可以被儲存到 Cell State 中。它會過濾輸入的資訊，只保留重要的部分。
Forget Gate	F_t	決定要從上一個時間點的 Cell State 中丟棄或遺忘哪些資訊。這有助於模型拋棄不再相關的舊記憶。
Output Gate	O_t	根據目前的輸入和 Cell State，決定要輸出什麼資訊。它會從 Cell State 中提取相關資訊，作為當前時間點的 Hidden State。
Cell State	C_t	LSTM 的核心，像一條傳送帶一樣在整個序列中傳遞資訊。它儲存了從過去到現在的重要長期記憶，其資訊可以透過遺忘門和輸入門來增加或刪除。

2.2 Social LSTM (含社交池化)

2.2.1 概念來源

Social LSTM [4]，原用於預測擁擠場域中之行人軌跡。其核心思想是：每個序列（行人、車輛、感測器節點）都有一條專屬 LSTM，但在每個時間步，個體可透過一個 Social Pooling Layer 接收鄰居隱藏狀態，從而隱式建模「互動」而非僅依賴自身歷史。此機制對交通流量預測特別吸引人，因為它不需要預先手動建立道路拓撲或鄰接矩陣，而是由模型自行學習空間依賴。

2.2.2 社交池化機制 (Social Pooling)

a. 網格劃分

對於目標節點 i 的當前座標 (x_t^i, y_t^i) ，以其為中心建立一個固定大小、離散化為 $M \times N$ 的空間網格。

b. 隱態分配

每一鄰居 j 的相對位移 $(x_t^j - x_t^i, y_t^j - y_t^i)$ 對應到網格座標 (m, n) 。若該格已有其他鄰居，其隱藏狀態將以 向量加總 形式累積。

c. 社交張量

因此第 (m, n) 格的張量切片為

$$H_t^i(m, n, :) = \sum_{j \in \mathcal{N}_i} 1_{mn}[x_t^j - x_t^i, y_t^j - y_t^i] h_{t-1}^j$$

其中 $1_{mn}[\cdot]$ 為指示函數、 \mathcal{N}_i 為鄰居集合。

d. 嵌入與拼接

H_t^i 先經一小型全連接層或 CNN，再與自身座標或速度特徵拼接，構成下一步 LSTM 的輸入。

2.2.3 完整更新流程

對每個節點 i ：

$$\begin{aligned} e_t^i &= \phi([p_t^i; \text{flatten}(H_t^i)]) \\ h_t^i &= \text{LSTM}(h_{t-1}^i, e_t^i) \end{aligned}$$

其中 p_t^i 可包 (x, y) 座標、時段指標等， $\phi(\cdot)$ 為非線性嵌入。

網格分辨率 (M, N) 於與半徑可視資料密度調整。

2.2.4 架構優勢

表 2 Social Pooling 架構優勢

面向	面向
拓撲需求	不需顯式鄰接矩陣，模型可直接從座標學習互動
互動捕捉	隱藏狀態共享可學得避讓、跟車等行為模式
可擴展性	每節點僅與自身網格交互，計算量隨鄰居數增加緩慢
應用於交通	自動感知鄰站流量互動，降低拓撲估計成本

2.2.5 與本研究關聯

在我國都市交通場景中，感測站位置固定而拓撲不完整。Social Pooling 透過 座標導向的隱式鄰居交互，正好滿足「無鄰接矩陣」建模需求。惟其單向量記憶限制對複雜流量模式的刻劃，故本研究將之與高容量記憶的 xLSTM 結合，提出 Social-xLSTM 以進一步提升對壅塞、事件等突發變化的敏感度與準確度。

2.3 擴展型 LSTM (xLSTM)

2.3.1 改進動機

儘管 LSTM 能解決梯度消失，其 單向量記憶 在三方面仍受限：

a. 無法即時修正存儲決策

一旦寫入，若日後出現更重要資訊，很難覆寫

b. 儲存容量受限

所有訊息須壓縮進一組標量細胞，導致對罕見事件如稀有字詞或突發壅塞的表徵不足

c. 序貫運算

memory mixing 牽涉隱藏層間遞迴，阻礙時間並行化

2.3.2 核心創新

表 3 xLSTM 核心元件與功能

元件	說明
指數門控 (Exponential Gating)	以 $e^{\tilde{f}_t}, e^{\tilde{f}_t}$ 取代 sigmoid，使模型可「重寫」舊記憶。另加穩定化狀態 m_t 避免溢位
sLSTM	保持標量記憶，加入正常化狀態 n_t 與新式記憶混合，兼具可重寫性與較低計算量
mLSTM	將記憶提升為矩陣 $C_t \in \mathbb{R}^{d \times d}$ ，以外積 $v_t k_t^T$ 寫入，對查詢 q_t 做關聯性檢索，無記憶混合，因而可並行計算
xLSTM Block	在殘差骨幹中交錯堆疊 sLSTM 與 mLSTM，並採前/後上投影以放大特徵維度，利於分離不同歷史情境

2.3.3 數學定義

a. sLSTM (Scalar-Memory LSTM)

$$c_t = f_t c_{t-1} + i_t z_t$$

$$n_t = f_t n_{t-1} + i_t$$

$$\tilde{h}_t = \frac{c_t}{n_t}, h_t = o_t \odot \tilde{h}_t$$

$$z_t = \phi(\tilde{z}_t), \tilde{z}_t = W_z x_t + r_z h_{t-1} + b_z$$

$$i_t = \exp(\tilde{i}_t), \tilde{i}_t = W_i x_t + r_i h_{t-1} + b_i$$

$$f_t \in \{\sigma\}$$

b. mLSTM (Matrix-memory LSTM)

待補

2.4 本文提出的 Social-xLstm

本節詳細說明本文核心貢獻 Social-xLSTM。該模型將的「社交池化」(Social Pooling) 與「高容量、可重寫記憶」(xLSTM) 緊密結合，形成一個無需鄰接矩陣、僅靠座標即可自動學習節點依賴的交通流量預測框架，旨在回答第前述研究問題

2.4.1 模型總覽

a. 輸入特徵

$$x_t^i = [\underbrace{q_t^i}_{\text{當前流量}}, \underbrace{p_t^i}_{\text{當前車道佔有率}}, \underbrace{s_t^i}_{\text{當前車道速度}}, \underbrace{q^i}_{\text{車道數}}, \underbrace{t^i}_{\text{日期特真}}]$$

其中 i 為測站編號。

- b. 社交池化層 (Coordinate-Driven Social Pooling)

由座標 (x_i, y_i) 生成網格張量 H_t^i 表示鄰近節點上一時刻隱藏狀態的空間分佈。

- c. 嵌入 & 拼接

$$e_t^i = \phi([x_t^i; \text{flatten}(H_t^i)])$$

- d. xLSTM Block Stack

待補

- e. 解碼器

待補

2.4.2 Hybrid xLSTM 記憶設計

待補

2.4.3 研究問題

待補

第參章 資料集與前處理

本節說明本研究自零開始的資料蒐集與處理流程：先將原始資料整理為可用樣本，再進行格式化與編碼，使其符合模型輸入需求並支援高速載入。透過 I/O 最佳化策略，我們有效降低資料存取瓶頸，讓訓練過程能充分發揮硬體效能。

3.1 資料集來源

在該研究過程中，我們發現了台灣對於各縣市市區的交通流量的資料並不完整，尤其是對於台灣中南部地區的交通流量資料更是缺乏。即時是對於交通流量資料的相對完整的台北市的資料，在市政府官網上許多資料文件都無法下載，有或者是像高雄市政府有提供即時交通流量的平台，但是該平台的資料並無法透過 API 的方式取得，而是需要透過網頁爬蟲的方式來取得資料，這樣的方式不僅耗時且不穩定，也不一定符合法規。因此，我們決定使用台灣公路總局所提供的即時公路交通流量資料作為我們的研究資料集。這些資料包含了各省道交通即時交通流量資訊(每一鐘更新)，並且公路總局也提供了 API 的方式來取得資料，並有說明資料的使用規範，這樣的資料來源不僅完整且穩定，並且也符合我們的研究需求。

3.2 資料集蒐集

達成資料集蒐集，目前已蒐集到 66371 筆資料，約一個半月的資料量，為了蒐集這些資料，我們設計一個資料蒐集的程式，該程式會定時的去抓取台灣公路總局所提供的即時公路交通流量資料，並將資料存入指定的資料夾中。該程式會以使用符合規範的頻率，也就是每一分抓取一次資料，以此來確保資料的完整性，並且也不會對於伺服器造成過大的負擔。下載的資料會以 xml 的格式儲存，且單次下載的大小約為 20MiB，一天的資料量約為 $20\text{MiB} \times 60 \times 24 = 28800\text{MiB}$ ，也就是約 28.8 GiB。為了能夠保證資料的完整性，該資料收集程式會在每天的 00:00:00 時會將前一天的資料進行壓縮，並將壓縮後的資料上傳至冷備份區上，將當天的資料進行備份。

3.3 資料前處理

在資料蒐集完成後，我們會對資料進行前處理，以便於後續的資料分析與模型訓練。我們會將所需資料解壓縮，選擇需要的資料檔案，並將該檔案內容去除掉一些不必要的欄位，並將資料轉換成我們需要的格式。我們會將資料由 xml 轉換成 json 的格式，並將資料存入指定的資料夾中，以便後續使用。此外，我們把原先按照時間分檔的方式改為按照地區分塊，以此來最佳化模型在訓練時的資料載入速度，以提高 GPU 的使用率。

3.4 選擇交通預測所需監測站

蒐集公路局所提供之各監測站資料，包括動態、靜態資料，為了方便選擇所需要做交通預測的範圍，我們利用靜態資料所提供各監測設備所在地點之經

緯度，以南投為中心點，繪製一張各監測設備的相對位置，如圖 2 所示，最後選擇位於高屏交界處的監測器，如圖 3，用來作為本研究交通流量預測的目標站點，因該範圍的站點分布不像其他點壅擠，較為分散，為了模擬在一般市區的車流量情況，因此選擇該範圍。

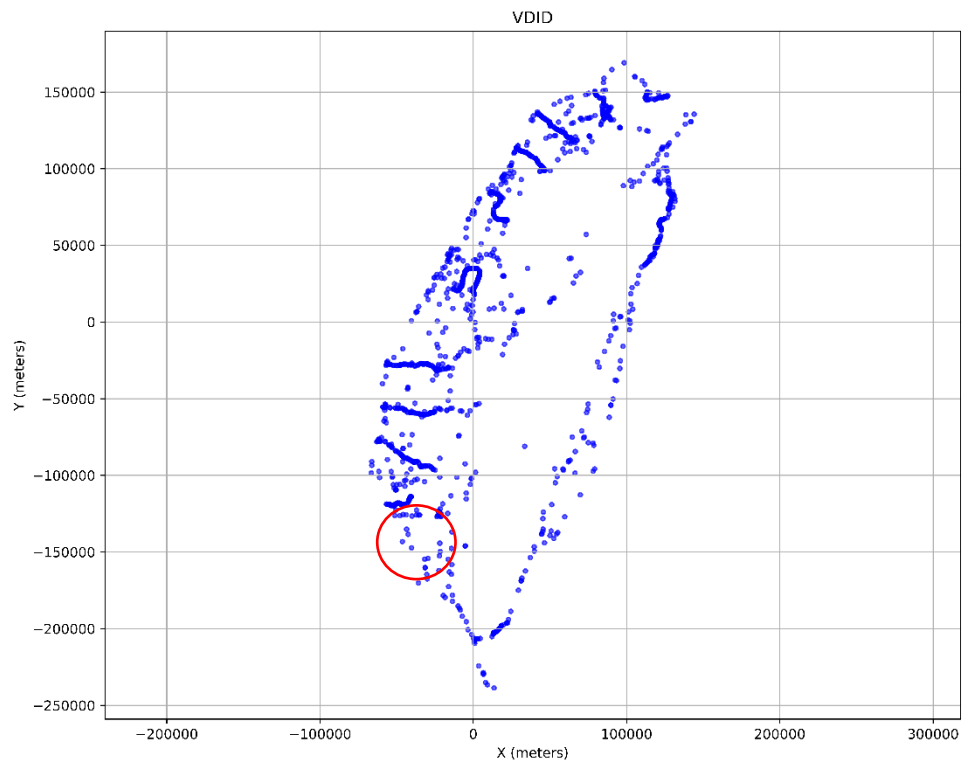


圖 2 公路局所提供各監測設備之相對位置




圖 3 所選擇監測站點分布

第肆章 實驗結果

4.1 效能評估

第伍章 應用設計

第陸章 預期結果

6.1 預期結果

本研究旨在提出並驗證一種創新的交通流量預測方法 Social xLSTM，以克服現有時空模型在缺乏明確道路拓撲資訊情境下的限制，具體目標如下：

1. 建立一個能在缺乏完整或部分缺失的網路拓撲資訊情況下，透過歷史交通數據自動學習與推導感測站間動態關聯的深度學習模型。
2. 提升短期與中期交通流量預測之準確性及即時性，以便更有效地支援即時交通訊號控制、事件管理與應急響應等智慧交通系統應用。
3. 通過多種實際交通數據集的實證研究，詳細評估 Social xLSTM 框架在不同交通環境下的模型效能、適應性與穩定性，並與現有主流時空模型進行性能對比分析。
4. 降低現有交通預測模型對完整拓撲或感測點連接資訊之依賴，有效減少資料前處理與建模成本，並提升模型實際應用之可行性。
5. 提供一個具有通用性與可擴展性的模型架構，除交通流量預測外，也能適用於其他類似的時空動態預測問題，促進相關研究之廣泛應用與發展。

6.2 目前完成工作

- i. 資料集蒐集
- ii. 資料集前處理
- iii. 最佳化資料集載入
- iv. 基本模型建立

6.3 預期完成工作

- i. Social xLSTM 程式碼實現
- ii. 模型訓練集驗證
- iii. 應用設計及落地

第柒章 期中進度

7.1 進度甘特圖

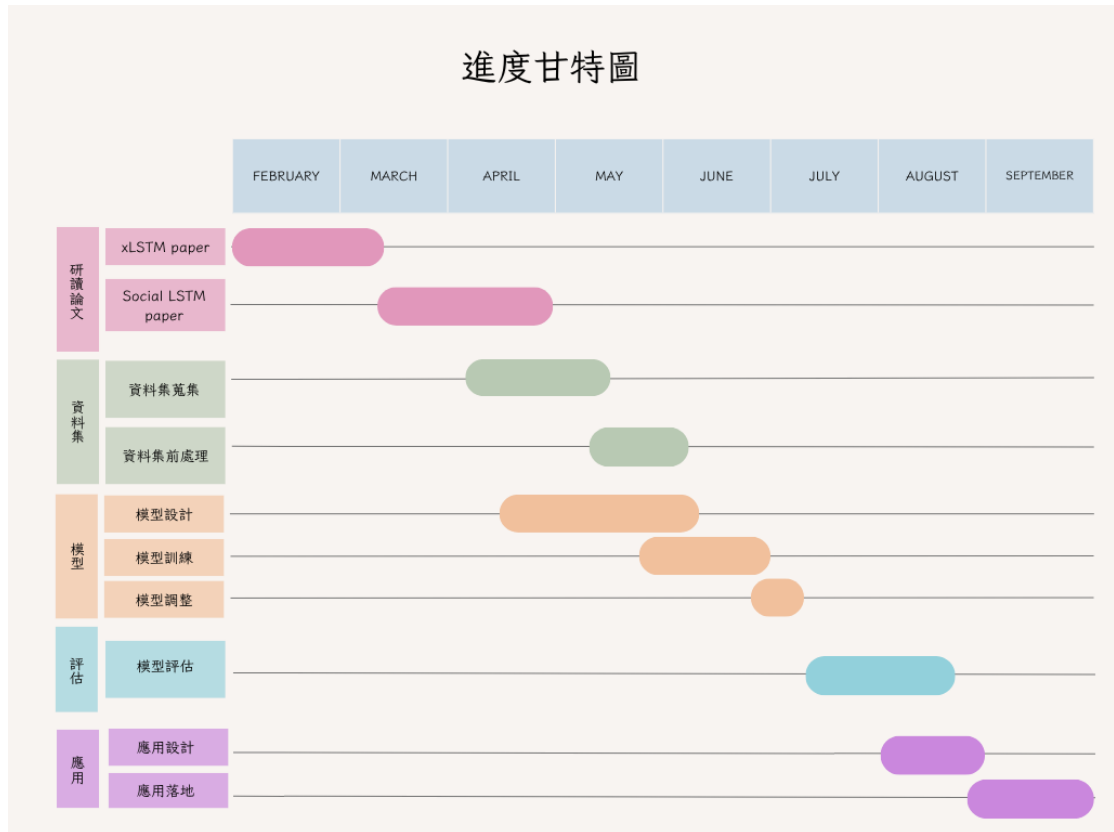


圖 4 進度甘特圖

7.2 實驗結果

參考文獻

- [1] S. Hochreiter 且 J. Schmidhuber, “Long short-term memory,” *Neural Computation*, 第 冊 9, 編號 8, pp. 1735-1780, 1997.
- [2] T. N. Kipf 且 M. Welling, “Semi-Supervised Classification with Graph Convolutional Networks,” 於 *International Conference on Learning Representations (ICLR)*, 2017.
- [3] A. V. e. al., “Attention is all you need,” 於 *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [4] A. Alahi, K. Goel, V. Ramanathan, A. Robicquet, L. Fei-Fei 且 S. Savarese, “Social LSTM: Human trajectory prediction in crowded spaces,” 於 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [5] M. Beck, J. Brandstetter, S. Du 且 S. Hochreiter, “xLSTM: Extended Long Short-Term Memory,” arXiv, 2024.